

FUNDAMENTOS DA INTELIGÊNCIA ARTIFICIAL

Aula 06 - Redes *RBF*
(*Radial Basis Function Networks*)

Prof. Rafael G. Mantovani



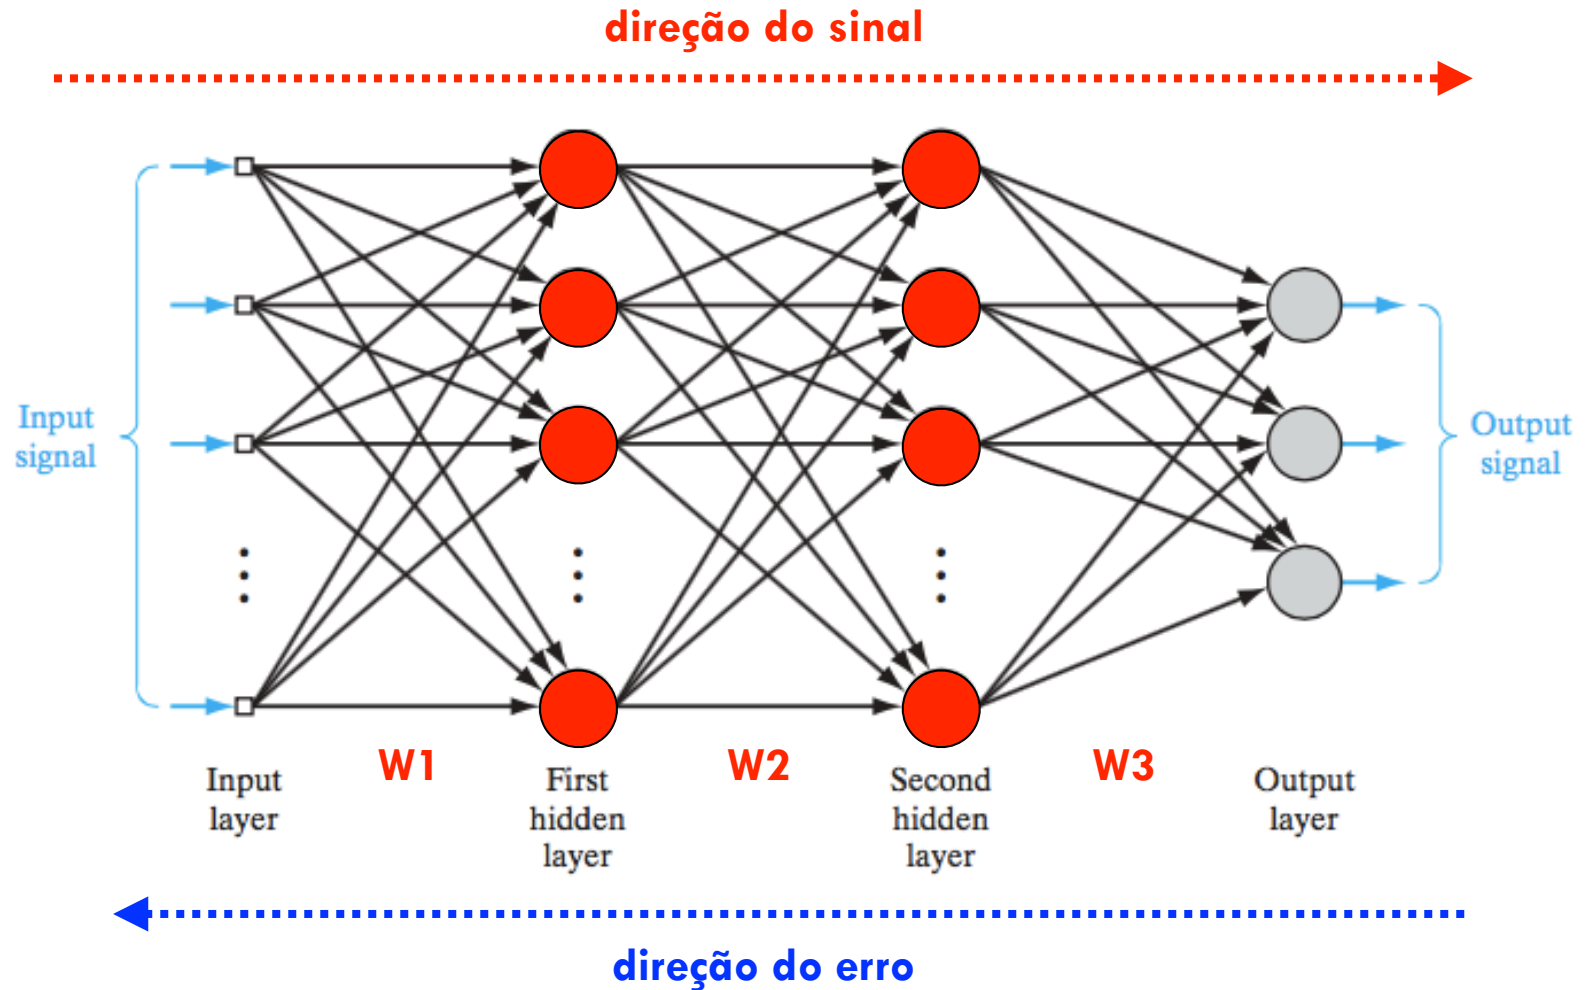
Roteiro

- 1 Introdução**
- 2 Redes com Funções de Base Radial (RBF)**
- 3 Algoritmo de Treinamento**
- 4 Exemplo**
- 5 Síntese / Próximas Aulas**
- 6 Referências**

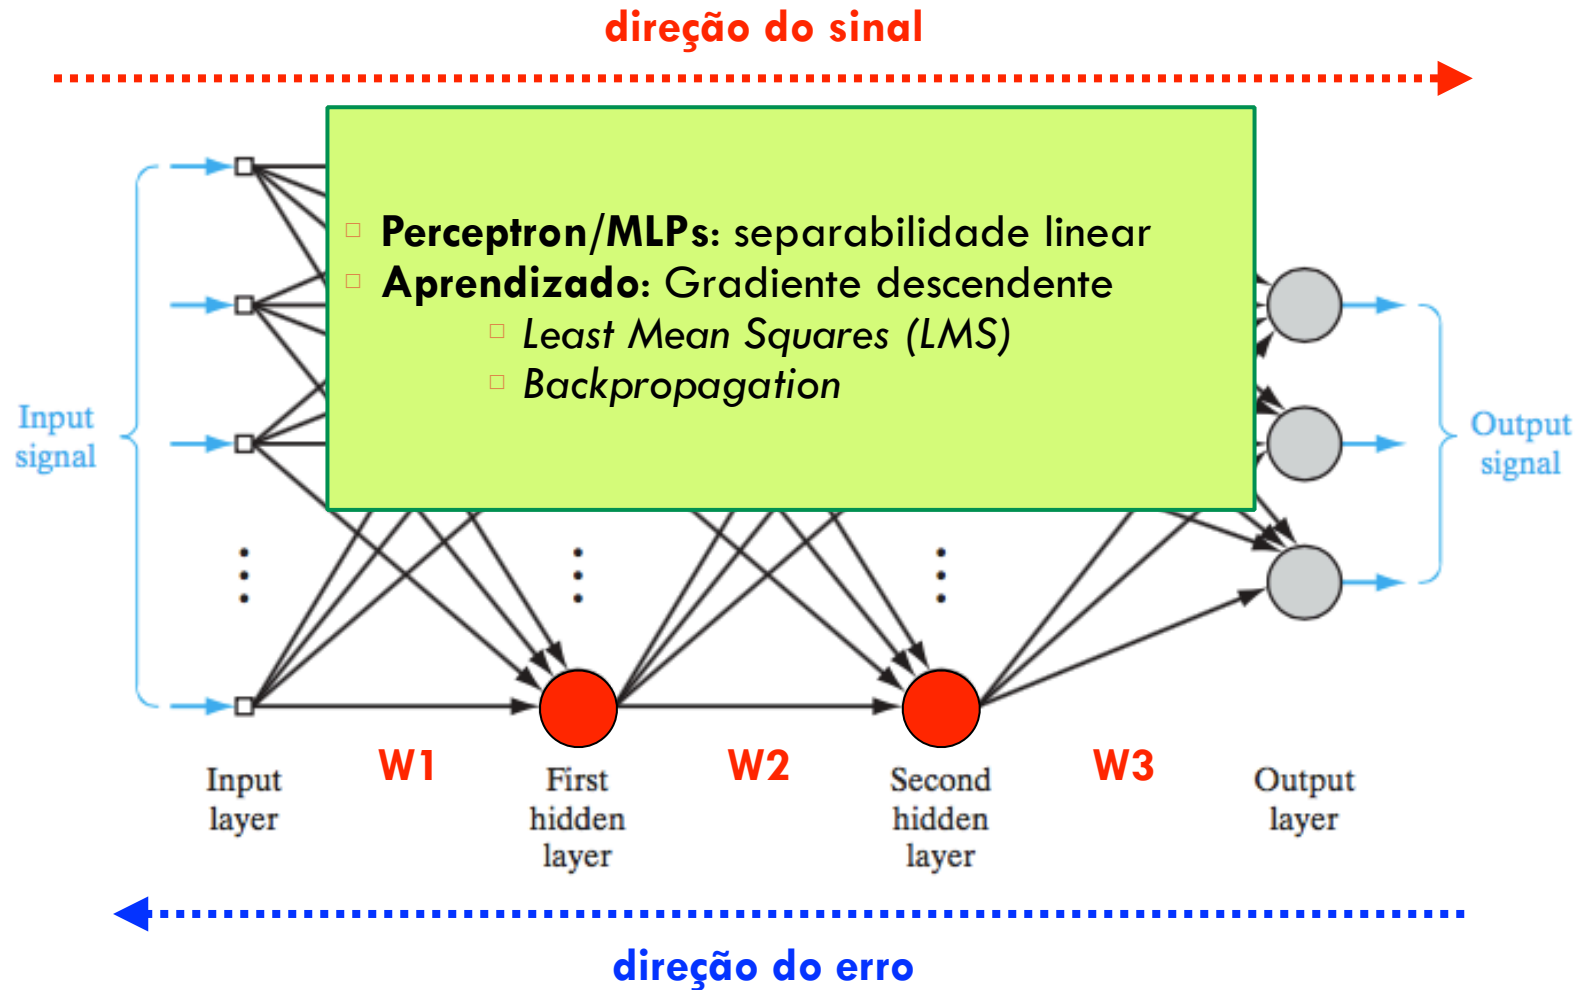
Roteiro

- 1** Introdução
- 2** Redes com Funções de Base Radial (RBF)
- 3** Algoritmo de Treinamento
- 4** Exemplo
- 5** Síntese / Próximas Aulas
- 6** Referências

Introdução



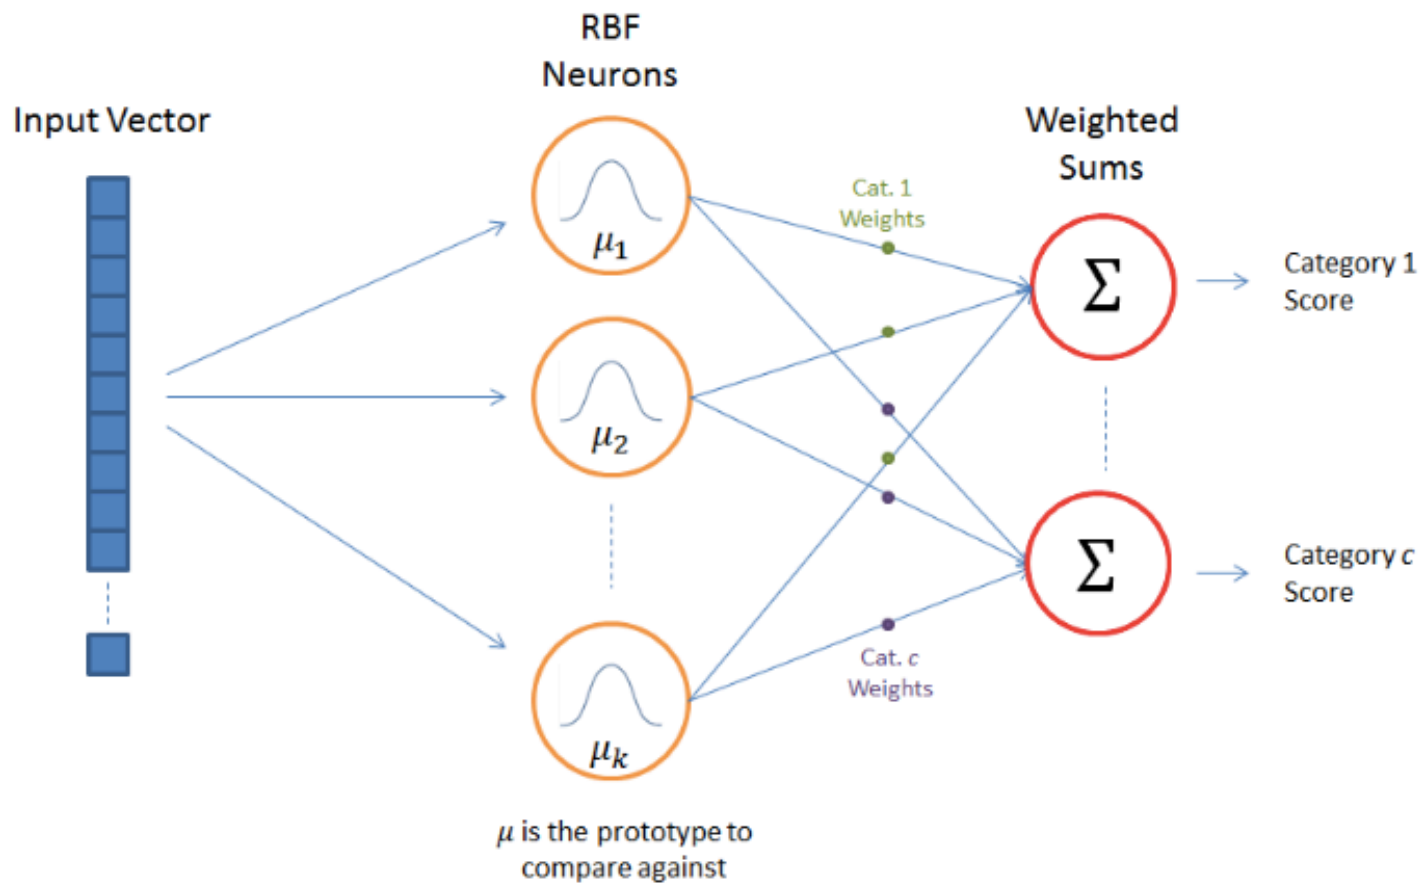
Introdução



Introdução

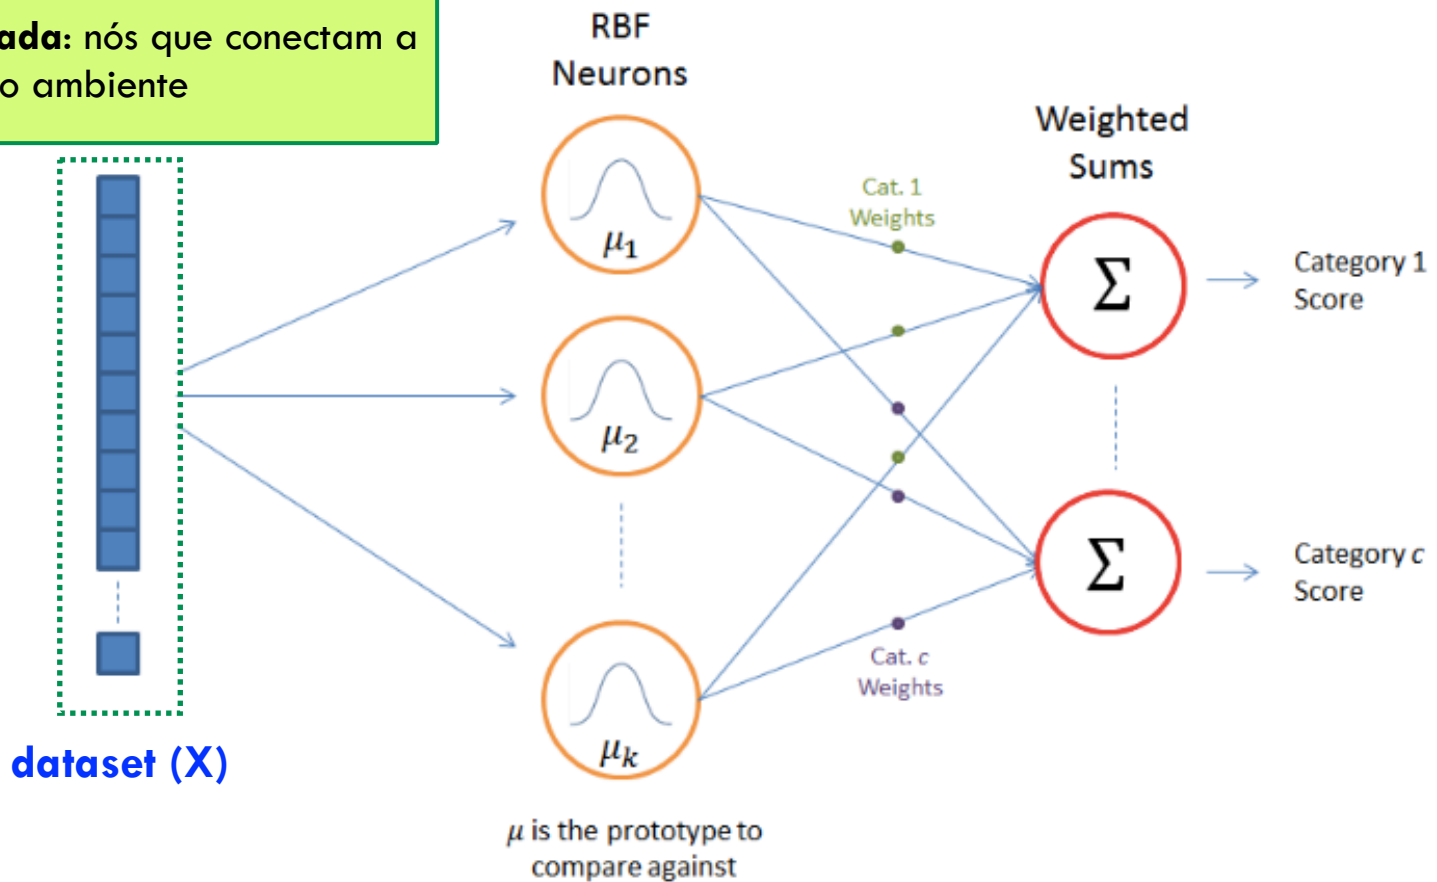
- Treinamento pode ser feito de várias maneiras
 - ***Backpropagation*** é apenas uma delas
- Abordagem diferente (híbrida)
 1. Transformar um conjunto de exemplos não linearmente separáveis em outro, com grande chances de ser linearmente separável (**Teorema de Cover, 1965**)
 2. Segunda fase que completa a classificação.
- Redes com Funções de Base Radial (RBFs)

Introdução

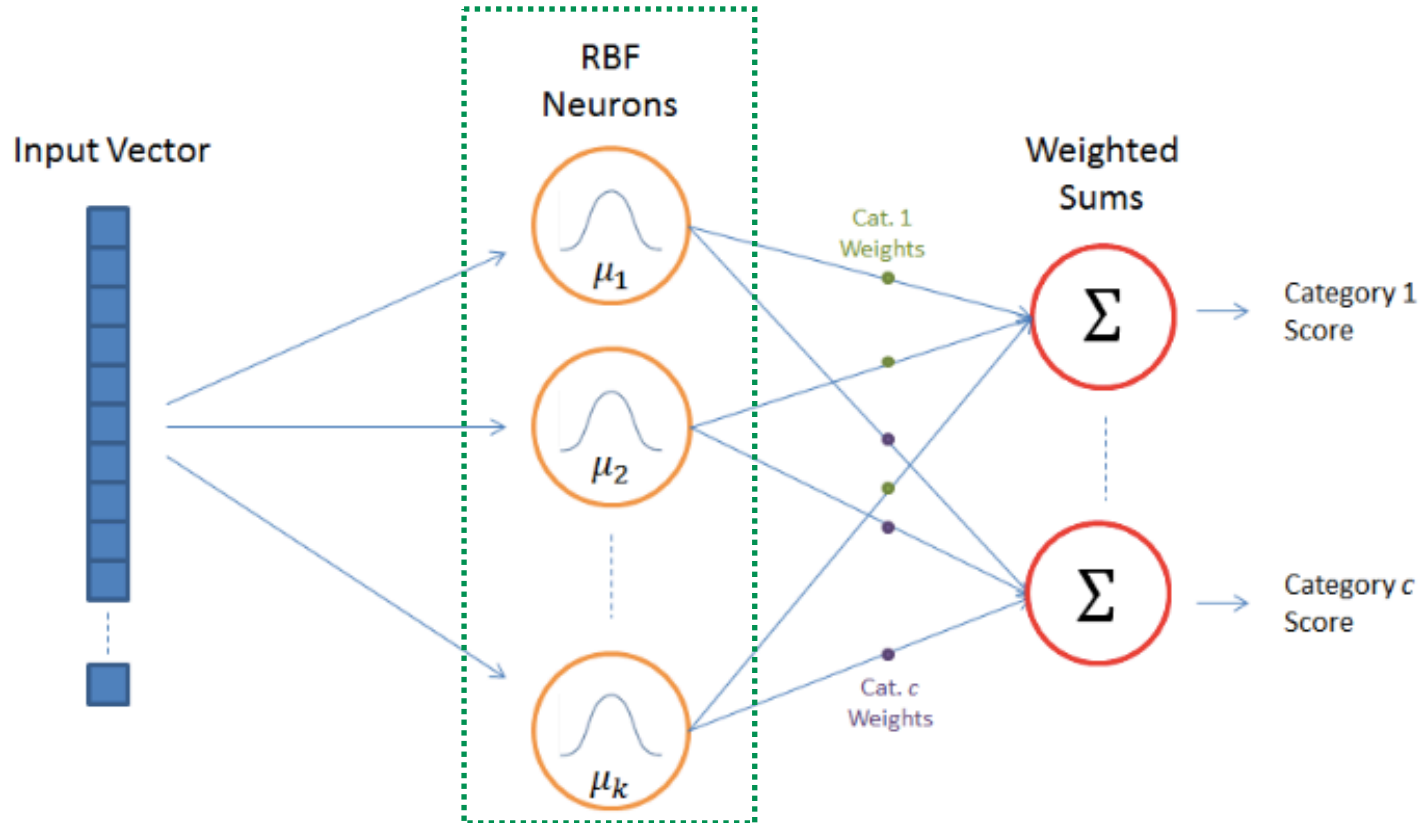


Introdução

- 1. **Entrada:** nós que conectam a rede ao ambiente

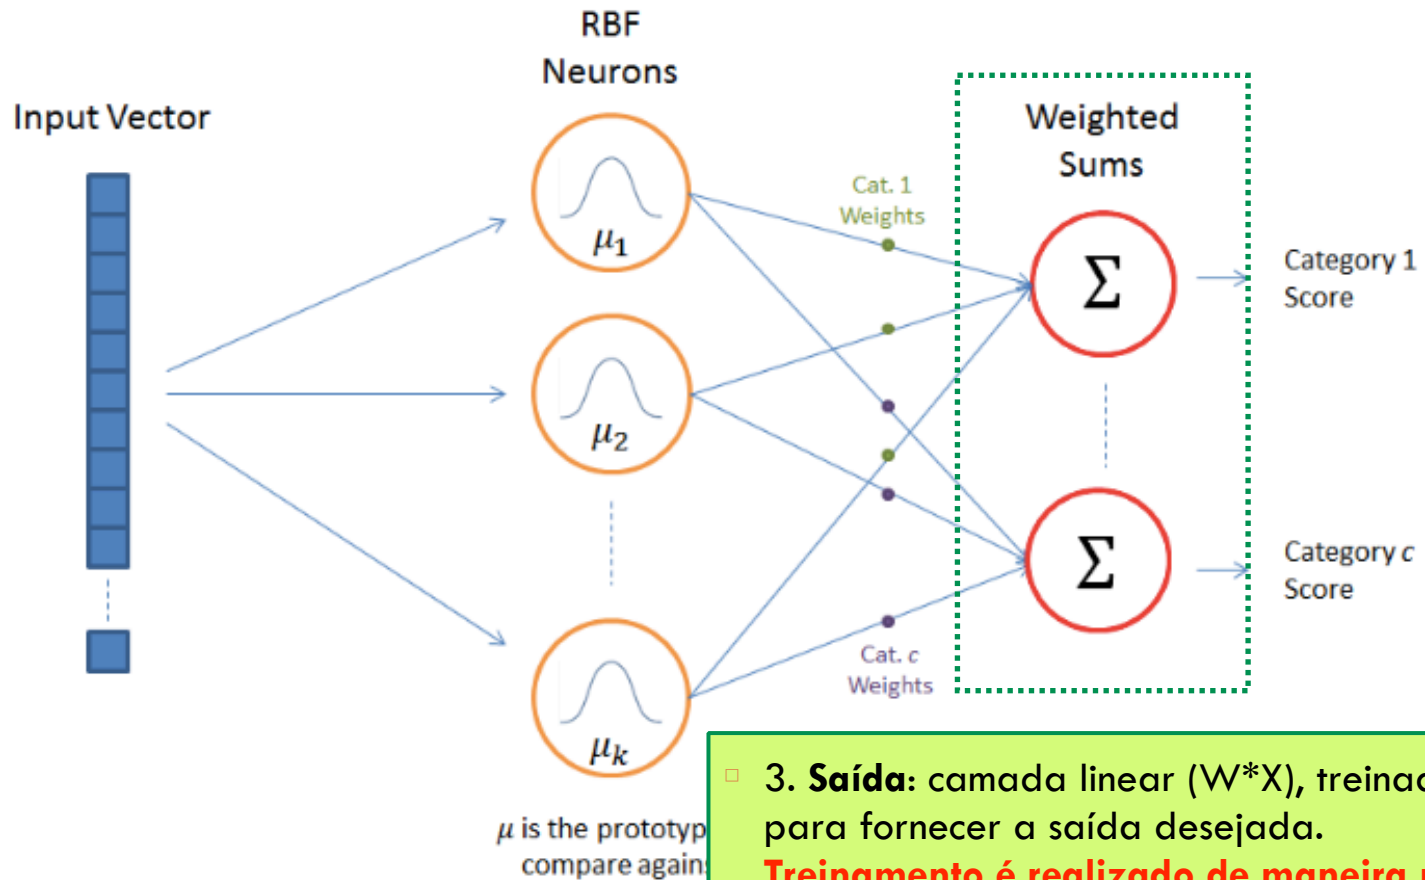


Introdução






- **2. Escondida:** transformação não-linear das entradas. **Treinamento é realizado de maneira não supervisionada.**

Introdução




- 3. **Saída:** camada linear ($W \cdot X$), treinada para fornecer a saída desejada.
Treinamento é realizado de maneira não não-supervisionada.


Introdução




Introdução



**linearmente
separável**



**esfericamente
separável**



**quadraticamente
separável**

- Exemplos de dicotomias separáveis por diferentes superfícies de decisão, considerando um conjunto de cinco pontos em duas dimensões

Pergunta?

Treinamento/
Aprendizado
Supervisionado


vs

Treinamento/
Aprendizado Não-
Supervisionado


Roteiro

- 1 Introdução
- 2 Redes com Funções de Base Radial (RBF)
- 3 Algoritmo de Treinamento
- 4 Exemplo
- 5 Síntese / Próximas Aulas
- 6 Referências

Redes RBF

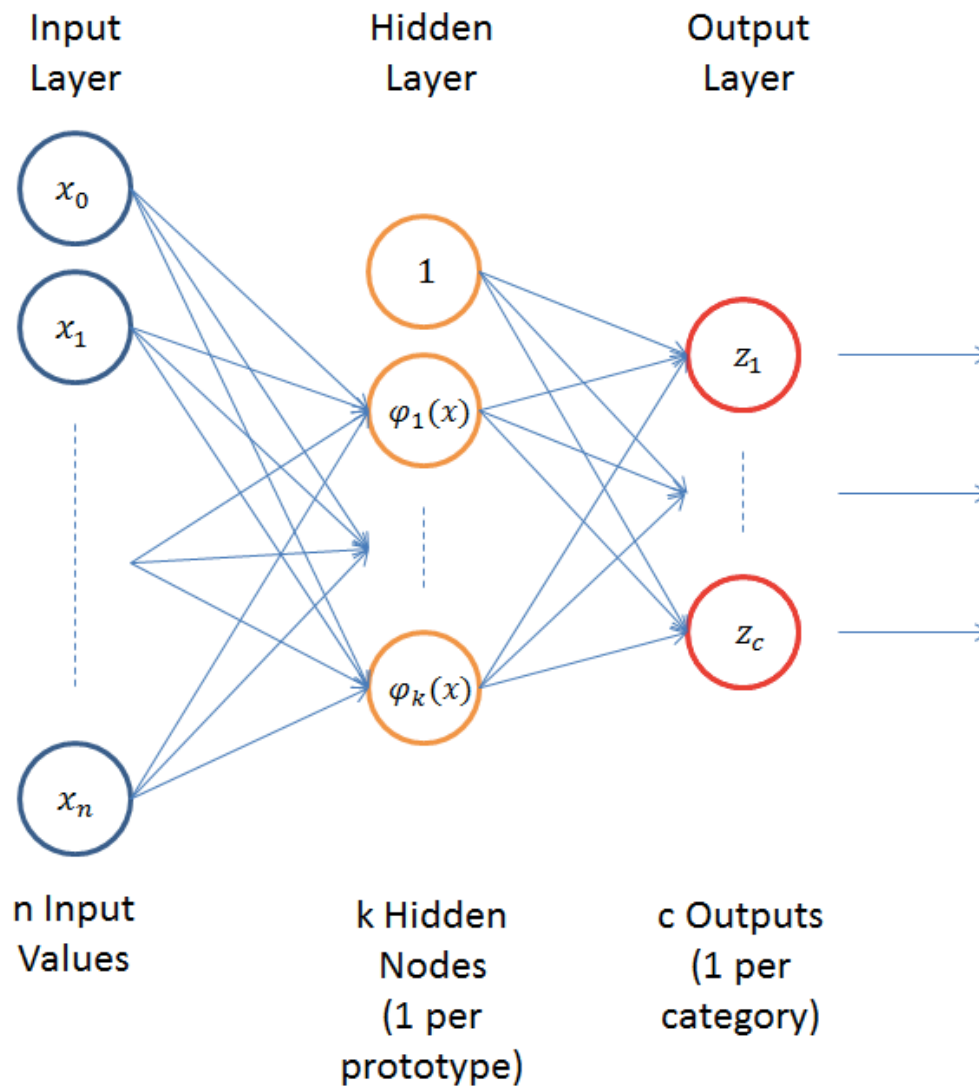


Redes RBF

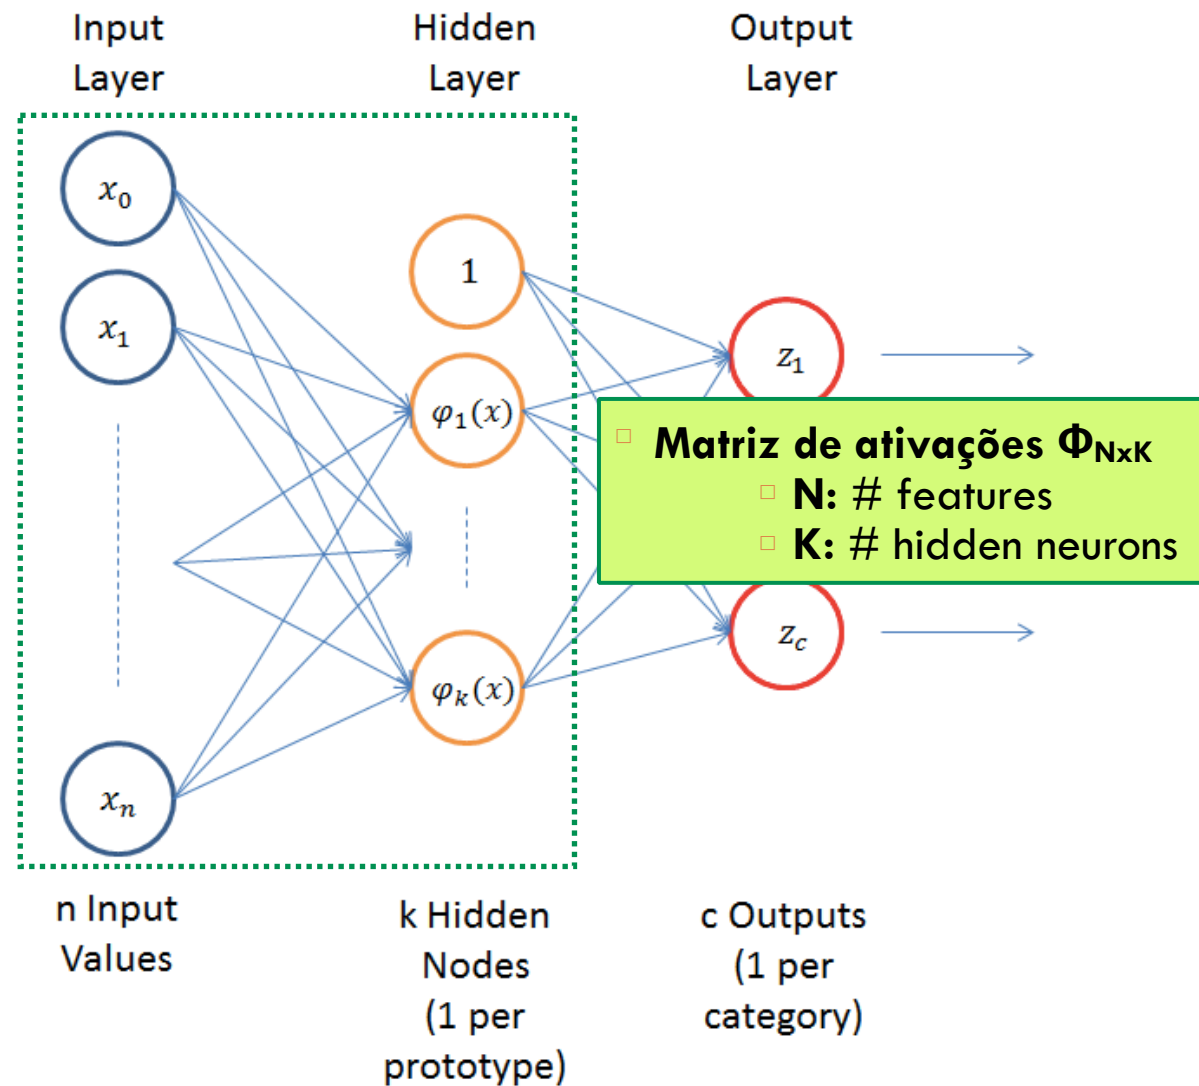


Distinction between MLP and RBF

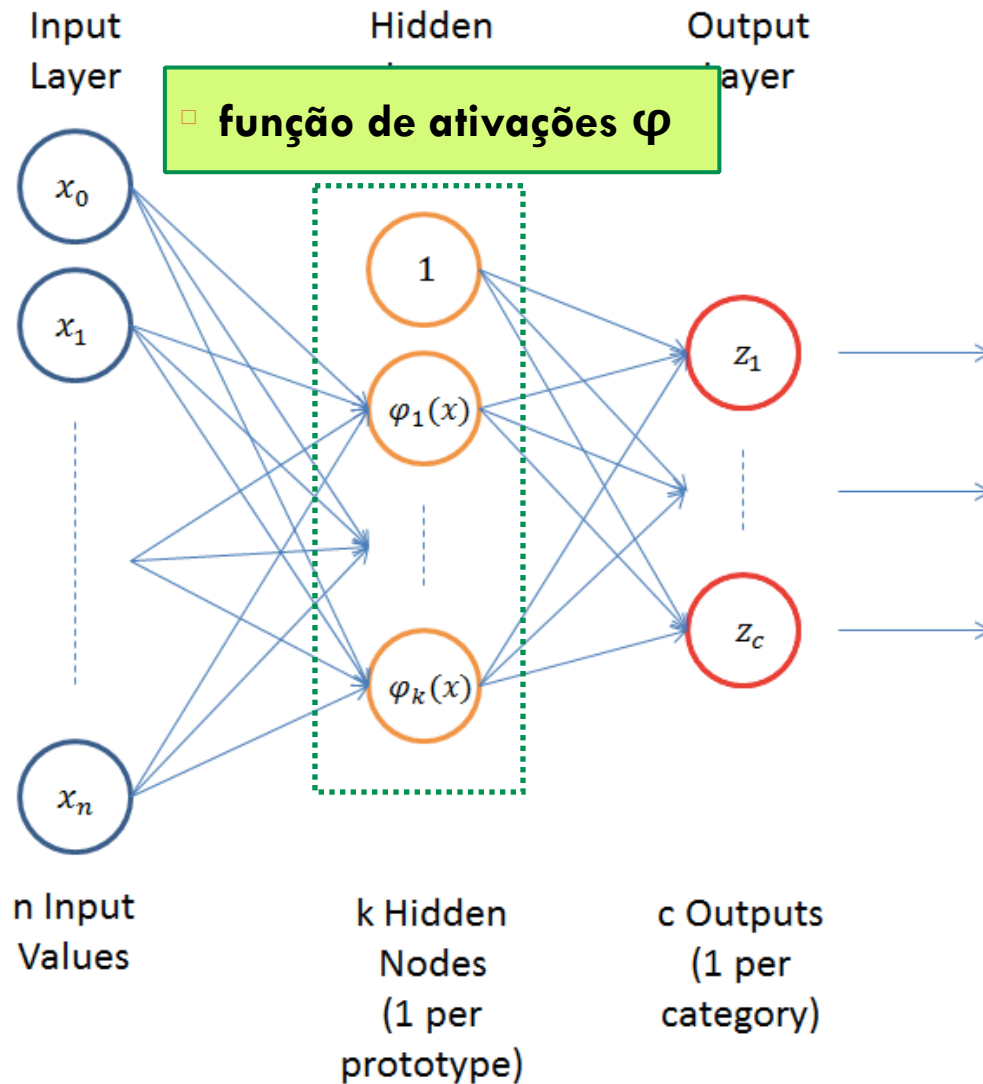
Redes RBF



Redes RBF




Redes RBF



Redes RBF

- função de ativação dos neurônios RBF:

$$\varphi(x) = \exp^{-\gamma||x-\mu||^2}$$




Redes RBF

- função de ativação dos neurônios RBF:

$$\varphi(x) = \exp^{-\gamma||x-\mu||^2}$$


□ μ é um padrão/
exemplo de X



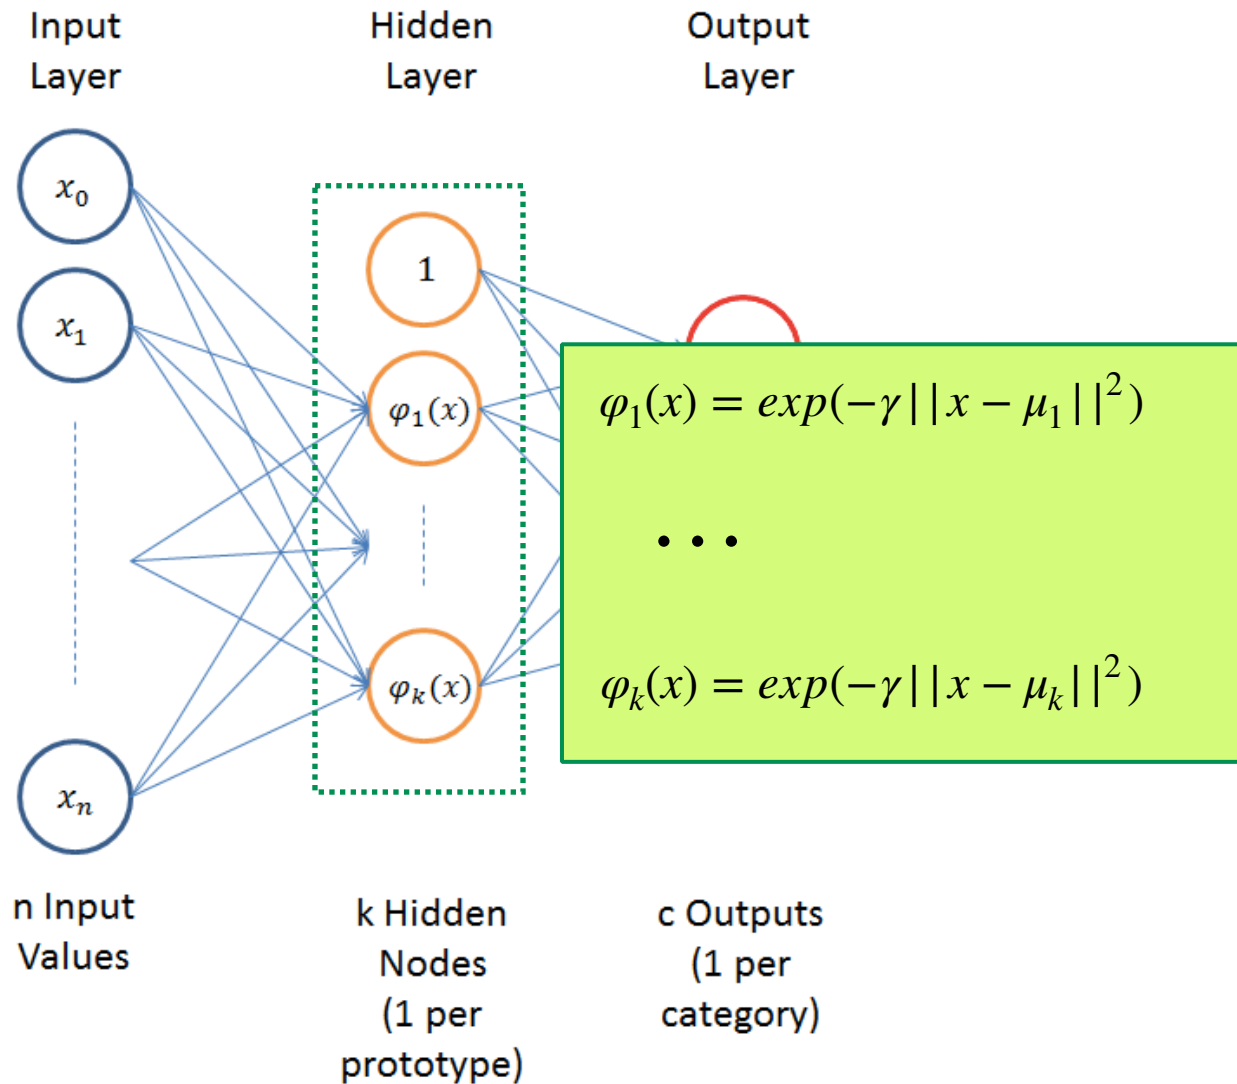
Redes RBF

- Variando γ :

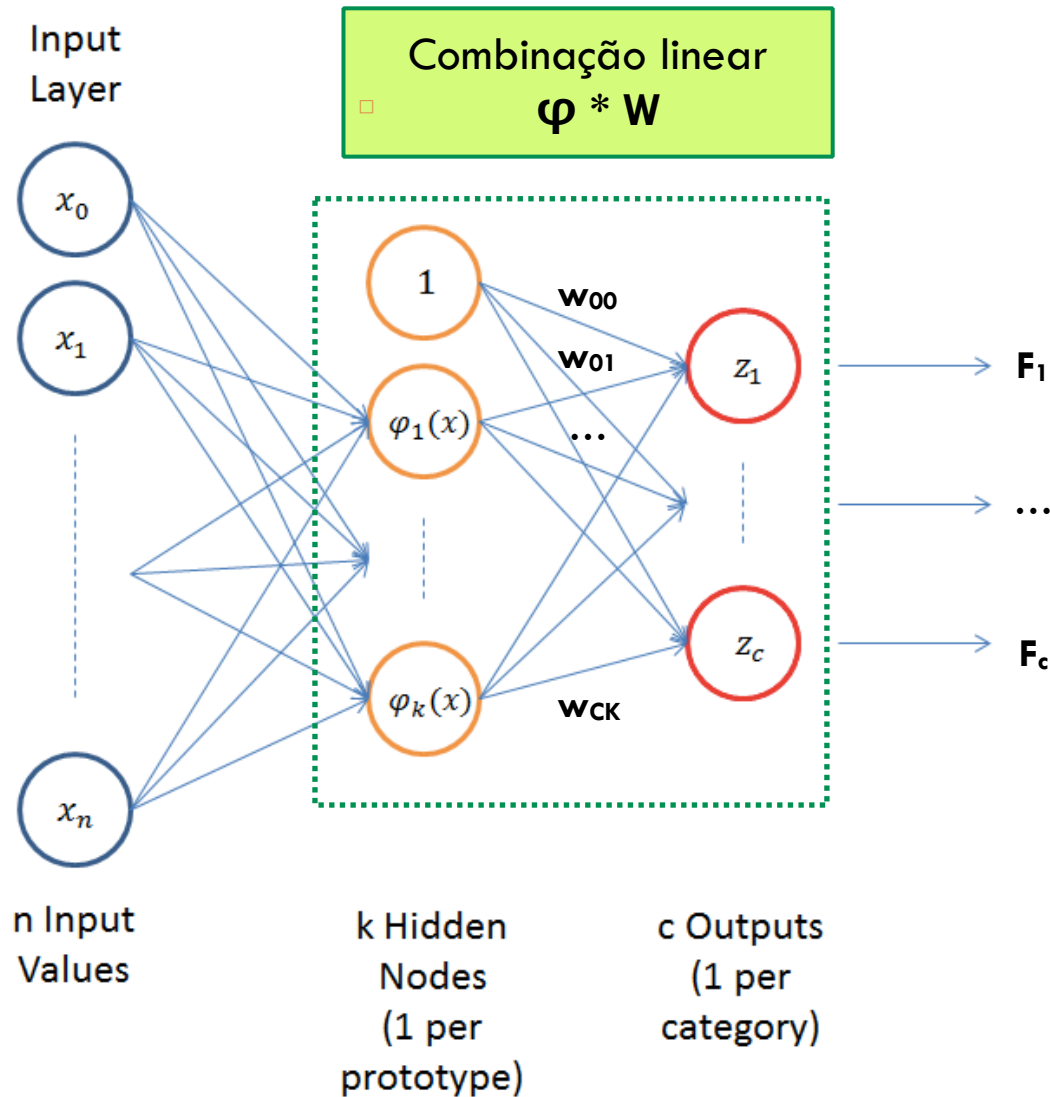
$$\varphi(x) = \exp^{-\gamma||x-\mu||^2}$$



Redes RBF



Redes RBF




Redes RBF

- Cada neurônio de saída tem a forma:


$$F(\mathbf{x}) = \sum_{j=1}^K w_j \varphi(\mathbf{x}, \mathbf{x}_j)$$

- cada unidade ocupa é uma RBF $\varphi(\mathbf{x}, \mu)$
- $J = 1, \dots, K$
- K é menor que N


Exemplo



Exemplo



Exemplo



Roteiro

- 1 Introdução
- 2 Redes com Funções de Base Radial (RBF)
- 3 Algoritmo de Treinamento
- 4 Exemplo
- 5 Síntese / Próximas Aulas
- 6 Referências

Algoritmo de treinamento

- $F(\mathbf{x}) = \sum_{i=1}^N w_i \varphi(\|\mathbf{x} - \mathbf{x}_i\|)$ pode ser vista como um conjunto de equações lineares para os coeficientes desconhecidos (pesos w_i):

$$\begin{bmatrix} \varphi_{11} & \varphi_{12} & \cdots & \varphi_{1N} \\ \varphi_{21} & \varphi_{22} & \cdots & \varphi_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ \varphi_{N1} & \varphi_{N2} & \cdots & \varphi_{NN} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_N \end{bmatrix}$$

$$\varphi_{ij} = \varphi(\|\mathbf{x}_i - \mathbf{x}_j\|), \quad i, j = 1, 2, \dots, N$$

Algoritmo de treinamento

$$\mathbf{d} = [d_1, d_2, \dots, d_N]^T$$

$$\mathbf{w} = [w_1, w_2, \dots, w_N]^T$$

- Os vetores \mathbf{d} e \mathbf{w} representam o vetor de saídas desejadas, e o vetor de pesos, respectivamente. N é o número de exemplos de treinamento
- Φ é a matriz $N \times N$ de elementos φ_{ij} : $\Phi = \{\varphi_{ij}\}_{i,j=1}^N$

Algoritmo de treinamento

- A matriz $\phi = \{\varphi_{ij}\}_{i,j=1}^N$ é chamada **matriz de interpolação**. Ela pode ser reescrita na forma:

$$\phi \mathbf{w} = \mathbf{x}$$

- Assumindo que ϕ é invertível, pode-se encontrar os pesos \mathbf{w} por meio de:

$$\mathbf{w} = \phi^{-1} \mathbf{x}$$

- Para a não singularidade de ϕ , todos os pontos $\{\mathbf{x}_i\}_{i=1}^N$ devem ser diferentes (distintos)

Algoritmo de treinamento

- Pode-se ter um bias alimentando a rede:

$$\underbrace{\begin{bmatrix} 1 & \exp(-\gamma\|x_1 - x_1\|^2) & \cdots & \exp(-\gamma\|x_1 - x_N\|^2) \\ 1 & \exp(-\gamma\|x_2 - x_1\|^2) & \cdots & \exp(-\gamma\|x_2 - x_N\|^2) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & \exp(-\gamma\|x_N - x_1\|^2) & \cdots & \exp(-\gamma\|x_N - x_N\|^2) \end{bmatrix}}_{\Phi} \underbrace{\begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix}}_{\mathbf{w}} = \underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}}_{\mathbf{d}}$$

- Φ deixa de ser quadrada ($N \times N$), a formula de treinamento de \mathbf{W} precisa ser adaptada para:

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{d}$$

Algoritmo de treinamento


□ Passos:

1. definir a função φ (**gaussiana**)
2. definir o tamanho da camada oculta (**K**)
3. selecionar os **K protótipos** usados em cada uma das funções RBFs (unidades ocultas)
 1. agrupamento \rightarrow k-MEANS (centróides do algoritmo)
4. Computar os valores de Φ (matriz)
5. Estimar os pesos sinápticos W , baseados em Y

Roteiro


- 1 Introdução
- 2 Redes com Funções de Base Radial (RBF)
- 3 Algoritmo de Treinamento
- 4 Exemplo
- 5 Síntese / Próximas Aulas
- 6 Referências

Exemplo 2



- $\varphi_1 \rightarrow \mu_1 = (0,0)$
- $\varphi_2 \rightarrow \mu_2 = (0,1)$
- $\varphi_3 \rightarrow \mu_3 = (1,0)$
- $\varphi_4 \rightarrow \mu_4 = (1,1)$

$$\varphi_n(x) = e^{\frac{-\gamma ||x - \mu_n||^2}{2}}$$



Roteiro

- 1 Introdução
- 2 Redes com Funções de Base Radial (RBF)
- 3 Algoritmo de Treinamento
- 4 Exemplo
- 5 Síntese / Próximas Aulas
- 6 Referências

Síntese

- RBFs
 - três camadas (entrada, oculta, saída)
 - mapeamento não linear (entrada, oculta)
 - unidades gaussianas (RBFs)
 - k centróides/protótipos
 - mapeamento linear (oculta, saída)
 - treinamento é uma regressão de várias equações lineares

Próxima Aula


- Implementação de Redes RBF
- Deep Learning
- SVMs

- Revisão/atendimento (quinta)
- Prova (sexta)


Roteiro

- 1** Introdução
- 2** Redes com Funções de Base Radial (RBF)
- 3** Algoritmo de Treinamento
- 4** Exemplo
- 5** Síntese / Próximas Aulas
- 6** Referências

Literatura Sugerida



(Haykin, 1999)



(Freeman & Skapura, 1991)

Perguntas?

Prof. Rafael G. Mantovani

rgmantovani@uel.br

Exercício

epoch	θ_{h0}	θ_{h1}	θ_{o0}	W^{h00}	W^{h10}	W^{h01}	W^{h11}	W^{o00}	W^{o01}
0	0.05	0.06	0.07	0.2	0.15	0.35	0.18	0.10	0.12
1									
2									

- $X = \text{XOR dataset}$
- $\eta = 0.2$
- $f(\text{net}) = \text{net}^3 + 0.5$
- $f'(\text{net}) = 3 * \text{net}^2$