

FUNDAMENTOS DA INTELIGÊNCIA ARTIFICIAL

Aula 08 - Breve introdução às Máquinas
de Vetores de Suporte (SVMs)

Prof. Rafael G. Mantovani



Roteiro

- 1** Introdução
- 2** Máquinas de Vetores Suporte (SVMs)
- 3** SVMs com margens rígidas
- 4** Exemplo
- 5** Síntese / Próximas Aulas
- 6** Referências


Roteiro

- 1** Introdução
- 2** Máquinas de Vetores Suporte (SVMs)
- 3** SVMs com margens rígidas
- 4** Exemplo
- 5** Síntese / Próximas Aulas
- 6** Referências

Introdução

- Máquinas de Vetores de Suporte
 - *Support Vector Machines (SVMs)*
 - Teoria do Aprendizado Estatístico (TAE)
- Buscam, em resumo, maximizar a margem de separação entre elementos de duas classes $\{+1, -1\}$
 - consistente com o princípio de minimização do Risco Empírico (RE)


Introdução




Teoria do Aprendizado Estatístico

- Definições:
 - f : é um classificador: dados \rightarrow espaço de classes
 - F : todos os classificadores que podem ser gerados por um algoritmo A
 - S : conjunto de treinamento (x_i, y_i) , N pares
 - usado para gerar um classificador $f' \in F$
 - obter o melhor classificador f^*

Teoria do Aprendizado Estatístico



Teoria do Aprendizado Estatístico



Exemplo de conjunto de dados de treinamento pertencentes a duas classes classificado segundo três diferentes hipóteses.

Teoria do Aprendizado Estatístico

- TAE :
 - condições matemáticas que permitam a escolha de um classificador f^* com bom desempenho para os conjuntos de treinamento e teste;
 - f^* é capaz de classificar os dados de treinamento da forma mais correta possível
 - f^* produz o menor erro durante o treinamento

SVMs


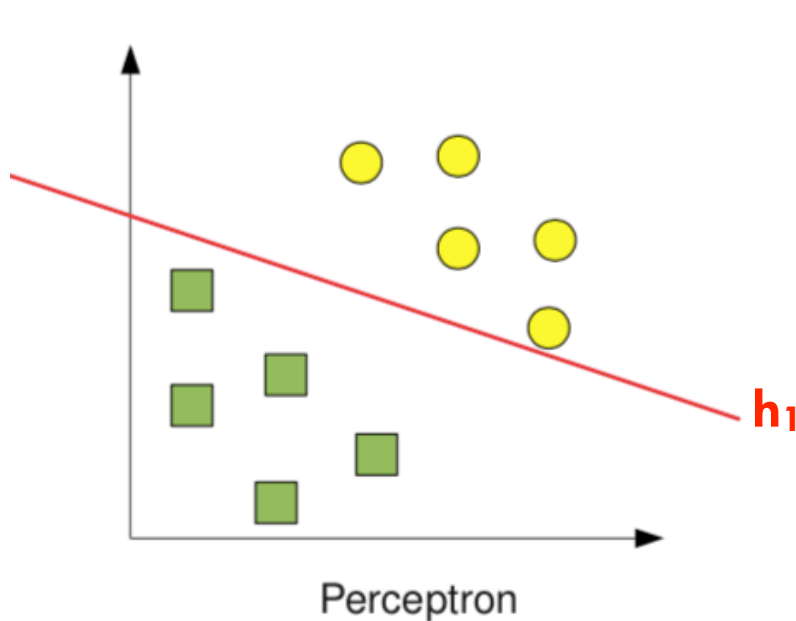
- Máquinas de Vetores de Suporte
 - originalmente para problemas binários $\{-1, +1\}$
 - adaptáveis para problemas multilasse
- SVMs lineares \rightarrow problemas linearmente separáveis
- SVMs não lineares \rightarrow problemas mais complexos

Roteiro


- 1 Introdução
- 2 Máquinas de Vetores Suporte (SVMs)
- 3 SVMs com margens rígidas
- 4 Exemplo
- 5 Síntese / Próximas Aulas
- 6 Referências

SVMs lineares

- Definem fronteiras lineares (hiperplanos) para separar dados
 - buscam maximizar a margem de separação entre classes



SVMs lineares



SVMs lineares


- **Margem**

- menor distância entre os exemplos do conjunto de treinamento e o hiperplano separador

- **Vetores suporte**

- pontos/exemplos (do dataset original) que ajudam a definir o hiperplano separador de margem mínima


SVMs lineares



Roteiro

- 1 Introdução
- 2 Máquinas de Vetores Suporte (SVMs)
- 3 SVMs com margens rígidas
- 4 Exemplo
- 5 Síntese / Próximas Aulas
- 6 Referências

SVMs com margens rígidas



Como buscamos pela máxima margem ou distância projetada entre x_1 e x_2 , buscamos maximizar:

$$d = x_1 - x_2 = \frac{2}{\|w\|}$$

Sendo a **distância mínima** entre o hiperplano separador e os dados de treinamento dada por:

$$\frac{1}{\|w\|}$$

Logo podemos maximizar esse termo acima ou minimizar o termo abaixo:

$$\|w\|$$

SVMs com margens rígidas

- Assim, propõe-se o problema de otimização (*primal*):

$$\underset{\mathbf{w}, b}{\text{Minimizar}} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\begin{aligned} \text{Com as restrições: } & \mathbf{w} \cdot \mathbf{x}_i + b \geq +1 \quad \forall i \\ & \text{e } \mathbf{w} \cdot \mathbf{x}_j + b \leq -1 \quad \forall j \end{aligned}$$

- As restrições são propostas para que não haja dado de treinamento entre as margens de separação das classes
 - Devido a isso dá-se o nome de SVM Linear com Margens Rígidas
- O problema a ser minimizado é quadrático:
 - Função objetivo é convexa, logo há somente um mínimo, que é o global

SVMs com margens rígidas

- Assim, propõe-se o problema de otimização (*primal*):

$$\underset{\mathbf{w}, b}{\text{Minimizar}} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\begin{aligned} \text{Com as restrições: } & \mathbf{w} \cdot \mathbf{x}_i + b \geq +1 \quad \forall i \\ & \text{e } \mathbf{w} \cdot \mathbf{x}_j + b \leq -1 \quad \forall j \end{aligned}$$

- As restrições são propostas para que não haja dado de treinamento entre as margens de separação das classes
 - Devido a isso dá-se o nome de SVM Linear com Margens Rígidas
- O problema a ser minimizado é quadrático:
 - Função objetivo é convexa, logo há somente um mínimo, que é o global

SVMs com margens rígidas

- Uma vez formulado o problema:

$$\begin{aligned} \text{Maximizar: } & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i \cdot \mathbf{x}_j \\ \text{Sujeito a: } & \begin{cases} \alpha_i \geq 0, \quad i = 1, \dots, n \\ \sum_{i=1}^n \alpha_i y_i = 0 \end{cases} \end{aligned}$$

- Pode-se resolvê-lo conforme visto anteriormente
 - Calculando a derivada parcial de L na direção dos alphas
 - Substituindo os alfas e aplicando a função objetivo original, i.e., aquela que considera a minimização de $\|\mathbf{w}\|^2$

SVMs com margens rígidas

Algoritmo 3.1 Determinação do hiperplano ótimo para conjuntos linearmente separáveis (Vert, 2001).

1: Para cada conjunto de treinamento linearmente separável $S = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$

2: Seja $\alpha^* = (\alpha_1^*, \dots, \alpha_n^*)$ a solução do seguinte problema de otimização com restrições:

3: Maximizar: $\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i \cdot \mathbf{x}_j$

4: Sob as restrições:
$$\begin{cases} \sum_{i=1}^n y_i \alpha_i = 0 \\ \alpha_i \geq 0, i = 1, \dots, n \end{cases}$$

5: O par (\mathbf{w}^*, b^*) apresentado a seguir define o hiperplano ótimo.

6: $\mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$

7: $b^* = -\frac{1}{2} \left[\max_{\{i|y_i=-1\}} (\mathbf{w}^* \cdot \mathbf{x}_i) + \min_{\{i|y_i=+1\}} (\mathbf{w}^* \cdot \mathbf{x}_i) \right]$


Roteiro

- 1 Introdução
- 2 Máquinas de Vetores Suporte (SVMs)
- 3 SVMs com margens rígidas
- 4 SVMs não-lineares
- 5 Síntese / Próximas Aulas
- 6 Referências

SVMs não-lineares


- Uso de SVMs lineares:
 - conjuntos de dados linearmente separáveis
 - ou possuem uma distribuição aproximadamente linear
- Porém há casos em que não é possível dividir satisfatoriamente os dados por um hiperplano

SVMs não-lineares




Espaço original

SVMs não-lineares

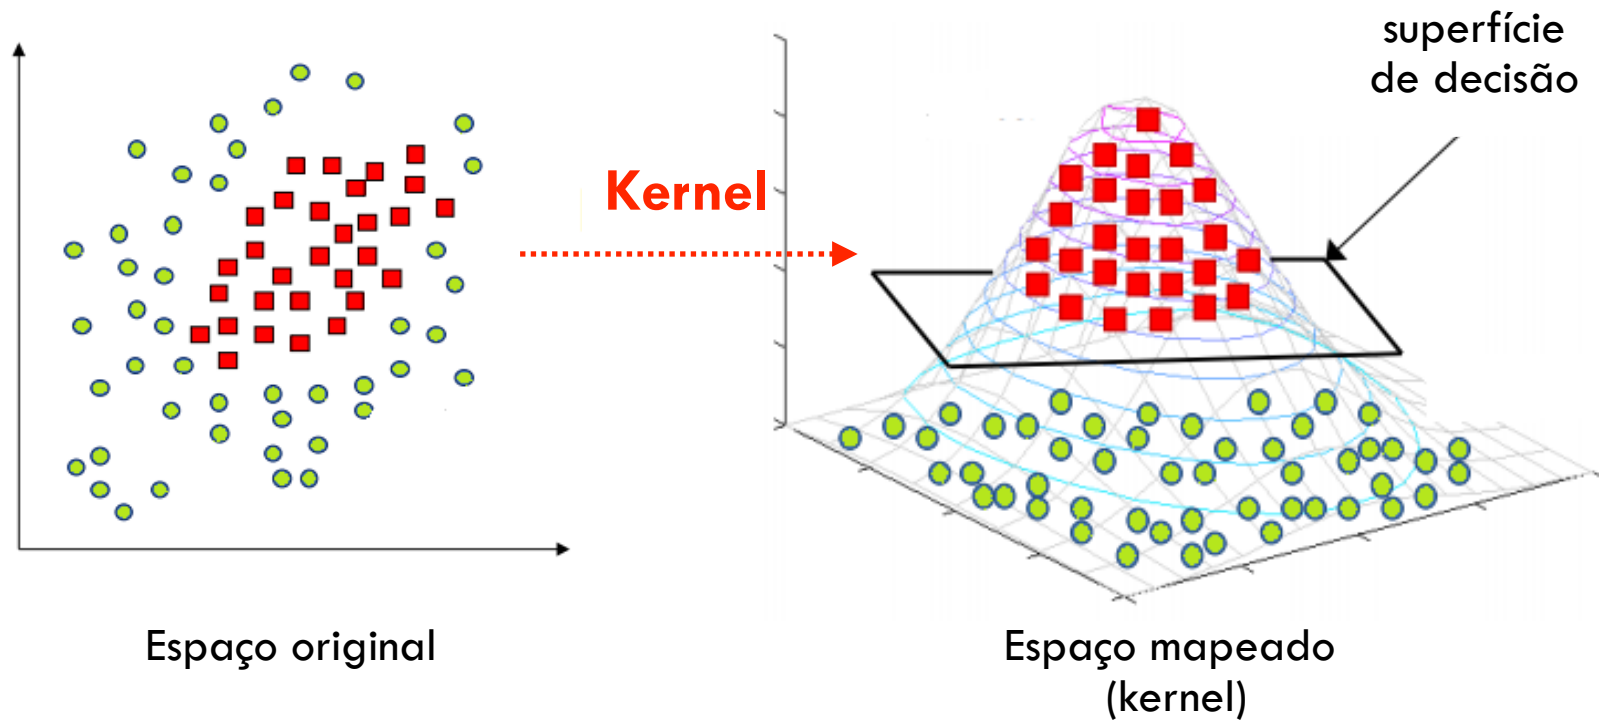


Espaço original



Superfície de decisão
não linear

SVMs não-lineares



SVMs não-lineares





- Kernéis:
 - realizam transformações de espaço
 - comum considerar um kernel sem mesmo saber exatamente o mapeamento que esse faz para os espaço de características
 - **Tipos:** Polinomial, Gaussiano, Sigmoidal, Linear

Kernels

Tipo de Kernel	Função $K(\mathbf{x}_i, \mathbf{x}_j)$ correspondente	Comentários
Polinomial	$(\mathbf{x}_i^T \cdot \mathbf{x}_j + 1)^p$	A potência p deve ser especificada pelo usuário
Gaussiano	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x}_i - \mathbf{x}_j\ ^2\right)$	A amplitude σ^2 é especificada pelo usuário
Sigmoidal	$\tanh(\beta_0 \mathbf{x}_i \cdot \mathbf{x}_j + \beta_1)$	Utilizado somente para alguns valores de β_0 e β_1

Tabela 5.1: Sumário dos principais Kernels utilizados nas SVMs (Haykin, 1999).

Kernels



SVMs multiclasse

- Estratégias:
 - 1-contra-todos
 - todos-contra-todos

Exemplo 1 [R]

- Executando SVMs em um dataset artificial

```
13 # seeing our data
14 plot(my.data[, -3], col=(ys+3)/2, pch=19, xlim=c(-1,6), ylim=c(-1,6))
15
16 # training a svm
17 svm.model = e1071::svm(type ~ ., data = my.data, type='C-classification',
18   kernel='linear', scale = FALSE)
19 svm.model
```

Exercício 01 (em sala)

- Adaptar o script “testeSVM.R” para plotar o hiperplano separador executando no iris
 - transformar o problema original em um problema de 2 classes
- 30 min

Exemplo2 [R]

- Executando SVMs no dataset *iris* (*mlr*)

```
4 library("mlr")
5
6 # iris (Species)
7 task = mlr::makeClassifTask(id = "iris", data = iris, target = "Species")
8 lrn = mlr::makeLearner(cl = "classif.svm", predict.type = "prob")
9 rdesc = mlr::makeResampleDesc(method = "CV", iters = 10, stratify = TRUE)
10 meas = list(ber, kappa, logloss, multiclass.aunu, timetrain, timepredict, timeboth)
11
12 res = mlr::resample(learner = lrn, task = task, resampling = rdesc, measures = meas,
13   models = FALSE, show.info = TRUE)
14 # print(res)|
```

Exercício 02 (em sala)

- Adaptar o script “testeSvmMlr” para comparar SVMs e MLPs executando no dataset “vehicle” multiclasse
 - testar diferentes kernels
- 45 min

Roteiro

- 1 Introdução
- 2 Máquinas de Vetores Suporte (SVMs)
- 3 SVMs com margens rígidas
- 4 SVMs não-lineares
- 5 Síntese / Próximas Aulas
- 6 Referências

Síntese

- **SVMs**
 - teoria do aprendizado estatístico
 - SVMs lineares
 - aprendizado redução de margem
 - SVMs não-lineares
 - Kernéis
 - Exemplo [R]


Próxima Aula

- Paradigma evolucionista
 - Algoritmos Evolutivos
 - Programação Evolutiva
 - Estratégia Evolutiva
 - Algoritmos Genéticos

Roteiro

- 1 Introdução
- 2 Máquinas de Vetores Suporte (SVMs)
- 3 SVMs com margens rígidas
- 4 SVMs não-lineares
- 5 Síntese / Próximas Aulas
- 6 Referências

Literatura Sugerida



(Haykin, 1999)



[Faceli et al, 2011]

Perguntas?

Prof. Rafael G. Mantovani

rgmantovani@uel.br